

JOURNAL FINAL DES ERREURS ETL ET RESOLUTIONS TECHNIQUE

Projet : Ingestion & Modélisation Olist E-Commerce (SQL Server)

Auteur : Tresor kitwanda

Période : 18 – 19 Août 2026

Statut : Résolu / Déploiement Validé

1. Synthèse Macro du Pipeline ETL

Métrique	Valeur
Volume Total Source (order_reviews)	99 224 lignes
Identifiants Unique (review_id)	98 410 distincts
Couples Uniques (review_id + order_id)	99 224 (100% d'unicité)
Taux de Rétention Final	100% (Aucune perte de donnée)

2. Historique et Analyse des Incidents

Incident #1 : Verrouillage du fichier CSV par un processus tiers

- **Horodatage :** 2026-08-18T10:52:26
 - **Code Erreur :** Msg 4861, Niveau 16, État 1
 - **Message SQL Server :** Cannot bulk load because the file "D:\Database\archive\olist_customers_dataset.csv" could not be opened. Operating system error code 32.
 - **Cause Racine :** Le fichier source était ouvert et verrouillé en écriture/lecture exclusive par une application externe (Excel / Éditeur de texte).
 - **Action Corrective :** Fermeture des processus tiers accédant au fichier et relance du job BULK INSERT.
-

Incident #2 : Débordement de mémoire sur mauvaise détection de fin de ligne

- **Horodatage :** 2026-08-18T11:01:46
 - **Codes Erreur :** Msg 4866, Niveau 16, État 8 | Msg 7301, Niveau 16, État 2
 - **Message SQL Server :** The bulk load failed. The column is too long in the data file for row 1, column 5.
 - **Cause Racine :** Les fichiers CSV encodés au format Unix/Linux utilisent le saut de ligne \n (0x0a), alors que SQL Server Windows attend \r\n. SQL Server n'a pas détecté la fin de la première ligne, provoquant l'accumulation de plusieurs lignes dans la dernière colonne.
 - **Action Corrective :** Ajout explicite de l'option ROWTERMINATOR = '0x0a' dans le script de chargement.
-

Incident #3 : Échec de conversion lié aux guillemets & décalage de virgules

- **Horodatage** : 2026-08-18T12:43:47
 - **Code Erreur** : Msg 245, Niveau 16, État 1
 - **Message SQL Server** : Conversion failed when converting the varchar value '"14409"' to data type int.
 - **Cause Racine** :
 1. Les valeurs numériques étaient entourées de guillemets doubles dans le CSV ("14409"), bloquant le cast direct vers INT.
 2. Des virgules étaient présente à l'intérieur de champs textuels (ex: rio grande do sul, brasil), provoquant un décalage des colonnes lors du découpage.
 - **Action Corrective** : Ajout du paramètre FIELDQUOTE = '"' dans la commande BULK INSERT pour traiter les chaînes encadrées par des guillemets contenant des virgules.
-

Incident #4 : Non-conformité de nommage et type décimal vers entier

- **Horodatage** : 2026-08-18T15:39:33 – 2026-08-19T09:21:07
 - **Codes Erreur** : Msg 207, Niveau 16, État 1 | Msg 245, Niveau 16, État 1
 - **Message SQL Server** : Invalid column name 'product_name_length' / Conversion failed when converting the varchar value '225.00' to data type int.
 - **Cause Racine** :
 1. Utilisation du mot anglais corrigé length alors que le jeu de données source Olist utilise l'orthographe lenght.
 2. Tentative de conversion directe d'une chaîne contenant un point décimal ('225.00') en INT.
 - **Action Corrective** : Alignement des scripts sur les noms réels (product_name_length) et utilisation d'un cast intermédiaire (DECIMAL(10,2) puis INT).
-

Incident #5 : Violation de la contrainte de clé primaire sur review_id

- **Horodatage** : 2026-08-19T13:42:03
 - **Code Erreur** : Msg 2627, Niveau 14, État 1
 - **Message SQL Server** : Violation of PRIMARY KEY constraint 'PK_order_reviews'. Cannot insert duplicate key in object 'dbo.order_reviews'.
 - **Analyse Approfondie** : L'analyse de la table staging_order_reviews a révélé 98 410 review_id uniques pour 99 224 lignes. Cependant, la combinaison (review_id, order_id) produit exactement 99 224 valeurs uniques. Il ne s'agit pas de vrais doublons, mais d'avis uniques attribués à plusieurs commandes.
 - **Action Corrective** : Redéfinition du modèle relationnel en remplaçant la clé primaire simple par une clé primaire composite (review_id, order_id).
-

3. Script SQL Final de Correction et Chargement

```
USE OlistCommerce;  
GO
```

```
-- 1. Nettoyage et reconfiguration de la structure
TRUNCATE TABLE order_reviews;
GO

IF EXISTS (SELECT * FROM sys.key_constraints WHERE name = 'PK_order_reviews')
BEGIN
    ALTER TABLE order_reviews DROP CONSTRAINT PK_order_reviews;
END
GO

ALTER TABLE order_reviews
ALTER COLUMN order_id VARCHAR(50) NOT NULL;
GO

-- 2. Application de la Clé Primaire Composite
ALTER TABLE order_reviews
ADD CONSTRAINT PK_order_reviews PRIMARY KEY (review_id, order_id);
GO

-- 3. Ingestion finale sécurisée depuis la Staging
INSERT INTO order_reviews (
    review_id,
    order_id,
    review_score,
    review_comment_title,
    review_comment_message,
    review_creation_date,
    review_answer_timestamp
)
SELECT
    review_id,
    order_id,
    CAST(review_score AS INT),
    review_comment_title,
    review_comment_message,
    TRY_CONVERT(DATETIME, review_creation_date),
    TRY_CONVERT(DATETIME, review_answer_timestamp)
FROM staging_order_reviews;
GO
```